

Resumen Estructurado de la Arquitectura Actual

El proyecto está diseñado para predecir trazas de consumo de potencia (series temporales) de circuitos digitales a partir de su estructura física y su actividad dinámica.

1. Flujo de Datos (Pipeline)

El sistema no procesa todos los datos de golpe. Utiliza un enfoque de "Carga Perezosa" (Lazy Loading) para manejar grandes volúmenes de datos y múltiples diseños de diferentes tamaños.

Preprocesamiento (create_dataset.py):

- Entrada: Archivos .v (Netlist), .lib (Librería de Celdas), .vcd (Actividad) y .data (Potencia real).
- Análisis Físico: Se extrae información física (área, fugas, tablas de potencia) del archivo .lib.
- Creación de Grafos Enriquecidos: Se crean grafos donde cada nodo (celda) tiene características físicas reales, no solo un tipo.
- Cálculo de Globales: Se determina el max_nodes global de todos los diseños para estandarizar tamaños después. Tenemos dificultad con los size mismatch.
- Salida Ligera: Se guardan archivos .pt que contienen solo la estructura del grafo y rutas a los archivos de actividad, no las matrices de actividad gigantes.
- Carga de Datos (utils.py - PowerTraceDataset):
- Cuando el entrenamiento pide una muestra, el Dataset carga el grafo ligero.

Transformación (PaddingTransform): Antes de entregar la muestra, rellena con ceros (padding) las matrices de características (x) y actividad (activity) para que coincidan con el tamaño max_nodes. Esto permite agrupar muestras de diferentes diseños en un mismo lote.

2. Arquitectura del Modelo (PowerPredictor)

El modelo es una red neuronal híbrida que combina el aprendizaje de grafos (para la estructura estática) con el aprendizaje de secuencias (para la actividad dinámica).

- Codificador Estático (GNN Encoder):

Tipo: GATConv (Graph Attention Network).

Función: Procesa el grafo del circuito (x, edge_index). Aprende cómo fluye la información a través de la estructura física del chip.

Entrada: Características de los nodos (Tipo de celda + Área + Leakage).

Salida: Un vector (embedding) que resume la estructura estática del circuito.

- Codificador Dinámico (Activity Encoder):

Tipo: Híbrido CNN + LSTM.

Función: Procesa la matriz de actividad temporal (activity).

CNN (1D): Extrae patrones locales de conmutación en el tiempo.

Adaptive Pooling: Reduce la dimensión temporal a un tamaño fijo, permitiendo manejar trazas de diferentes longitudes.

LSTM (Bidireccional): Analiza la secuencia temporal de las características extraídas para entender la evolución del consumo de energía.

Salida: Un vector (embedding) que resume el comportamiento dinámico.

- Cabezal de Predicción (Prediction Head):

Tipo: MLP (Perceptrón Multicapa).

Función: Combina (concatena) los embeddings estático y dinámico.

Salida Final: Una serie temporal de valores de potencia (la traza predicha).

3. Estrategia de Entrenamiento

Función de Pérdida (Loss): MSELoss (Error Cuadrático Medio). Mide qué tan lejos está cada punto de la predicción del valor real. Quizás no sea la mejor. Es difícil poder comparar trazas.

- Optimizador: Adam. Ajusta los pesos de la red para minimizar el error.

Métricas de Evaluación:

- MSE: Para la precisión punto a punto.
- DTW (Dynamic Time Warping): Para medir la similitud de la forma de la curva, incluso si está ligeramente desplazada en el tiempo.

