

Título: Inferencia de Potencia en Circuitos Digitales mediante Deep Learning Informado por la Física.

Equipo: José Alejandro Moreno, Valentina Restrepo

Problema: La estimación precisa del consumo de potencia (Power Analysis) es el principal cuello de botella en el diseño de circuitos modernos. Las herramientas estándares de la industria (EDA) ofrecen alta precisión pero requieren tiempos de simulación prohibitivos (horas o días), resultando en un proceso costoso que requiere de diversas herramientas de análisis comerciales. Por otro lado, las soluciones actuales de Machine Learning puramente basadas en datos (data-driven) sufren de baja generalización: aprenden a memorizar patrones de un circuito específico pero fallan estrepitosamente al inferir sobre diseños nuevos o tecnologías diferentes.

Motivación: Existe una oportunidad no explotada en la intersección entre el aprendizaje profundo y la física de semiconductores. En lugar de tratar el circuito como una "caja negra", podemos aprovechar la información determinista que ya poseemos (las librerías de celdas .lib y las leyes de Kirchhoff) para guiar el aprendizaje. Esto promete reducir la necesidad de datos masivos y garantizar predicciones que respeten las restricciones físicas reales a un costo computacional más bajo.

Alcance:

Este proyecto desarrollará un sistema de estimación de potencia post-synthesis que:

1. Utiliza Graph Neural Networks (GNN) para entender la topología del circuito. Esta será la información que se extraiga desde los archivos de Netlist que se tenga para cada uno de los diseños de los circuitos de interés.
2. Implementa una Capa Física Diferenciable que calcula el consumo basándose en la actividad predicha y las tablas de energía reales del fabricante. Esto permite enlazar la información disponible en la librería de los componentes y compuertas empleados con el análisis de la actividad de los circuitos.
3. Analiza el comportamiento dinámico de los circuitos mediante una red LSTM que transforma los datos de los archivos de actividad VCD a lo largo de un número fijo de puntos de datos.
4. Se validará comparando la precisión de las curvas de consumo de potencia predicha.

Estado del arte:

La estimación de potencia en circuitos integrados ha experimentado una transformación radical en la última década, impulsada por la necesidad de reducir los tiempos de validación en el flujo de diseño (EDA).

1. La Era de los Datos Puros (Data-Driven): Inicialmente, las soluciones de Machine Learning trataban la estimación de potencia como un problema de regresión vectorial simple o usaban Redes Convolucionales (CNNs) tratando la actividad del chip como "imágenes". Si bien estos métodos superaban en velocidad a las simulaciones tradicionales, carecían de una comprensión real de la topología del circuito, lo que limitaba severamente su precisión en diseños complejos.

2. El Salto a los Grafos (GNNs): Un avance significativo llegó con trabajos como GRANNITE (Zhang et al., 2020), que propuso por primera vez modelar el circuito mediante Graph Neural Networks (GNN). Al representar las compuertas como nodos y los cables como aristas, GRANNITE

logró capturar las dependencias espaciales de la señal y generalizar mejor entre diferentes familias de circuitos que los métodos anteriores. Sin embargo, este enfoque sigue siendo fundamentalmente una "caja negra": aprende correlaciones estadísticas, pero ignora las leyes físicas explícitas (como las ecuaciones de corriente de fuga o carga capacitiva) que gobiernan el hardware.

3. La Frontera Actual: Aprendizaje Informado por la Física (Physics-Informed): La tendencia más reciente (2024-2025) busca superar la dependencia masiva de datos mediante arquitecturas híbridas. Investigaciones muy recientes, como las presentadas en (Saha, 2025), demuestran que integrar restricciones físicas directamente en la función de pérdida o en la arquitectura de la red no solo mejora la precisión, sino que garantiza que las predicciones sean consistentes con la realidad física (ej. conservación de energía).

Posicionamiento del Proyecto: Nuestra propuesta se alinea con esta última ola de innovación. A diferencia de GRANNITE, que predice potencia directamente, nuestro modelo utiliza la GNN solo para predecir actividad, delegando el cálculo de potencia a una capa determinista basada en la librería .lib. Esto constituye un enfoque de "Caja Gris" que promete una generalización superior a la de los métodos puramente estadísticos.

Plan de trabajo:

- Datos: Grafos de Netlist (.v), Vectores de Actividad (.vcd) y Librerías Físicas (.lib).
- Métricas: Error Absoluto Medio Normalizado (NMAE) para precisión de potencia; DTW para la precisión de actividad predicha.
- Riesgos: Insuficiente memoria en grafos grandes (Mitigado con Lazy Loading y Graph Batching).

Referencias:

Zhang, H., Zhu, Y., & Li, H. (2020). GRANNITE: Graph neural network inference for transferable power estimation. En 57th ACM/IEEE Design Automation Conference (DAC) (pp. 1-6). IEEE. <https://doi.org/10.1109/DAC18072.2020.9218643>

Saha, D., Zhou, J., & Farahmandi, F. (2024). Physical Design-Aware Power Side-Channel Leakage Assessment Framework using Deep Learning. IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems. <https://ieeexplore.ieee.org/document/11043283>